# Initiation à l'encodage XML-TEI

Lou Burnard Consulting

# Objectif de cette session

Répondre à ces questions :

1. Qu'est-ce qu'un *texte* ? qu'est-ce qu'un *document* ?
2. Qu'est-ce que le *balisage* ?
3. C'est quoi le *balisage XML* ? Pourquoi est-il devenu si important ?

# La tournée numérique

Les sciences humaines et sociales s'occupent surtout du *texte*...

- (majoritairement non-numérique) les livres, les manuscrits, les fonds d'archives ...
- ainsi que d'autres manifestations culturelles/communicatives (de plus en plus numérisées) par ex., les sons, les images, les cahiers de recherches, les tweets

Les 'digital humanities' s'intéressent aux outils et aux techniques qui permettent de manipuler de manière intégrée toutes ces manifestations, et donc de gérer ce patrimoine de plus en plus signifiant.

Le balisage (markup, encodage) est une composante incontournable de ces manipulations

# Texte et texte numérique

Un texte peut être envisagé selon trois perspectives :

- Un texte a une existence physique, ayant des traits visuels qu'on peut (plus ou moins) transférer automatiquement d'une instance à une autre
- Un texte possède des propriétés linguistiques et structurelles, qu'on ne peut transcrire, traduire, ou transmettre qu'avec une compréhension humaine
- Un texte présente des informations sur le monde réel, qu'on peut comprendre (ou non) ou annoter, et qui nous permet de générer de nouveaux textes

Un balisage effectif devrait donc opérer dans ces trois directions.

# Un text numérique peut être …

un ‘substitut’ (surrogate) représentant l’apparence d’un document existant

Diary of Robert Graves 1935-39 and ancillary material



**July 27 Saturday**

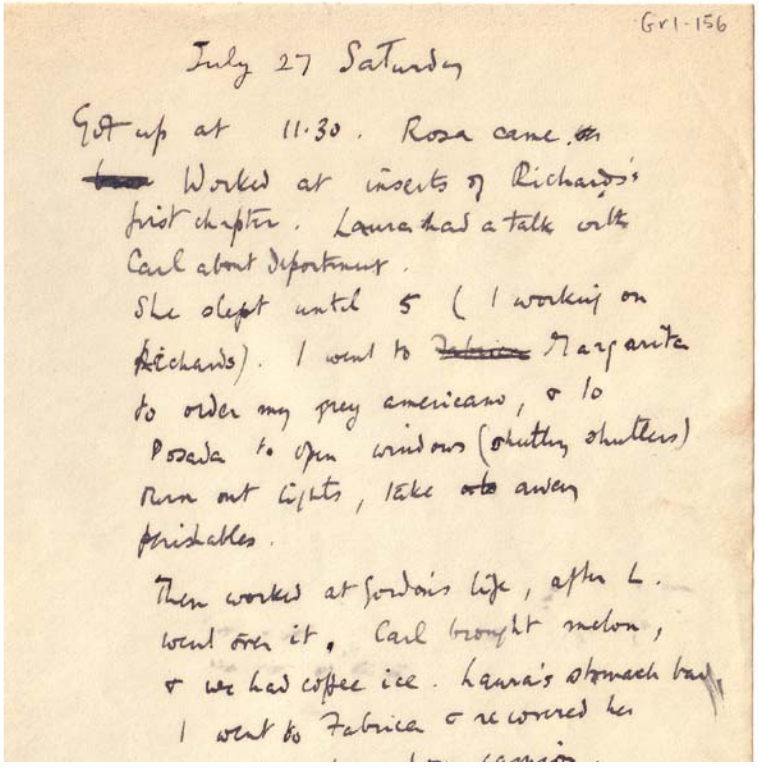

Gr1-156

July 27 Saturday

Got up at 11.30. Rosa came. ~~to~~
~~[illegible]~~ Worked at inserts in Richards's
first chapter. Laura had a talk with
Carl about departure.
She slept until 5 ( I working on
Richards). I went to ~~Fabrica~~ Margarita
to order my grey americano, & to
Rosa to open windows (shutters, shutters)
turn out lights, take ~~oto~~ away
perishables.
Then worked at Sordais life, after L.
went over it. Carl brought melon,
& we had coffee ice. Laura's stomach bad
I went to Fabrica & recovered her

# ... ou bien

une représentation du contenu linguistique, de sa structure, avec des annotations sur sa portée, son contexte..

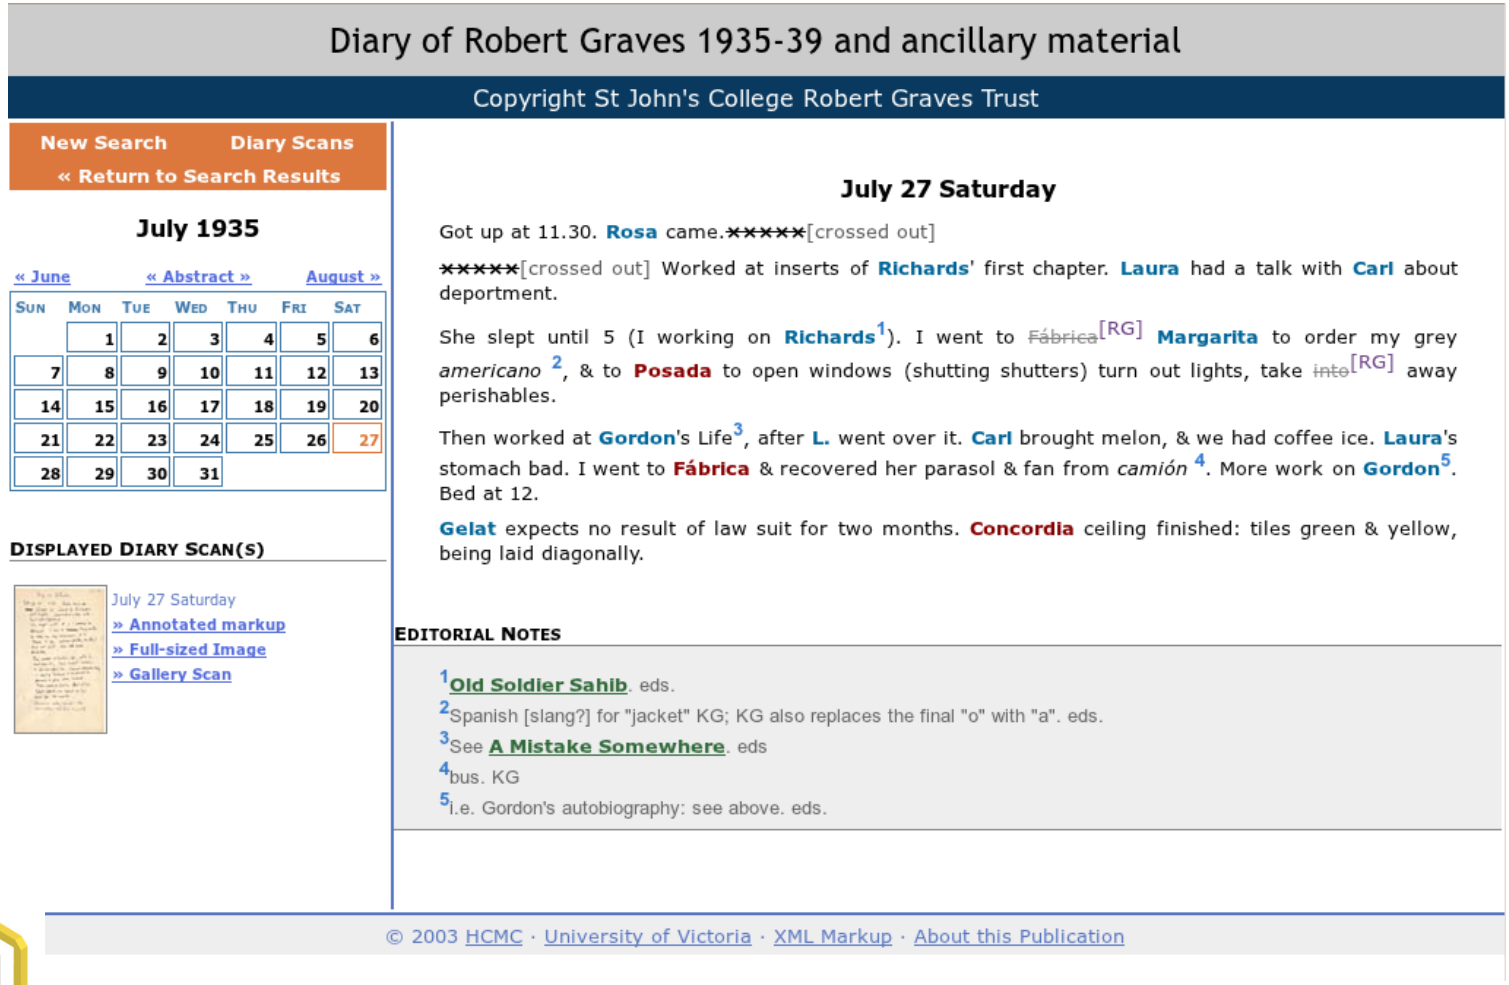

Diary of Robert Graves 1935-39 and ancillary material

Copyright St John's College Robert Graves Trust

New Search | Diary Scans

« Return to Search Results

**July 1935**

« June | « Abstract » | August »

| Sun | Mon | Tue | Wed | Thu | Fri | Sat |
|---|---|---|---|---|---|---|
| | 1 | 2 | 3 | 4 | 5 | 6 |
| 7 | 8 | 9 | 10 | 11 | 12 | 13 |
| 14 | 15 | 16 | 17 | 18 | 19 | 20 |
| 21 | 22 | 23 | 24 | 25 | 26 | 27 |
| 28 | 29 | 30 | 31 | | | |

**Displayed Diary Scan(s)**

July 27 Saturday
» Annotated markup
» Full-sized Image
» Gallery Scan

**July 27 Saturday**

Got up at 11.30. **Rosa** came.~~xxxxx~~[crossed out]

~~xxxxx~~[crossed out] Worked at inserts of **Richards**' first chapter. **Laura** had a talk with **Carl** about deportment.

She slept until 5 (I working on **Richards**[1]). I went to ~~Fábrica~~[RG] **Margarita** to order my grey *americano* [2], & to **Posada** to open windows (shutting shutters) turn out lights, take ~~into~~[RG] away perishables.

Then worked at **Gordon**'s Life[3], after **L.** went over it. **Carl** brought melon, & we had coffee ice. **Laura**'s stomach bad. I went to **Fábrica** & recovered her parasol & fan from *camión* [4]. More work on **Gordon**[5]. Bed at 12.

**Gelat** expects no result of law suit for two months. **Concordia** ceiling finished: tiles green & yellow, being laid diagonally.

**Editorial Notes**

[1] **Old Soldier Sahib**. eds.
[2] Spanish [slang?] for "jacket" KG; KG also replaces the final "o" with "a". eds.
[3] See **A Mistake Somewhere**. eds
[4] bus. KG
[5] i.e. Gordon's autobiography: see above. eds.

© 2003 HCMC · University of Victoria · XML Markup · About this Publication

# Que fait-on en numérisant un texte ?

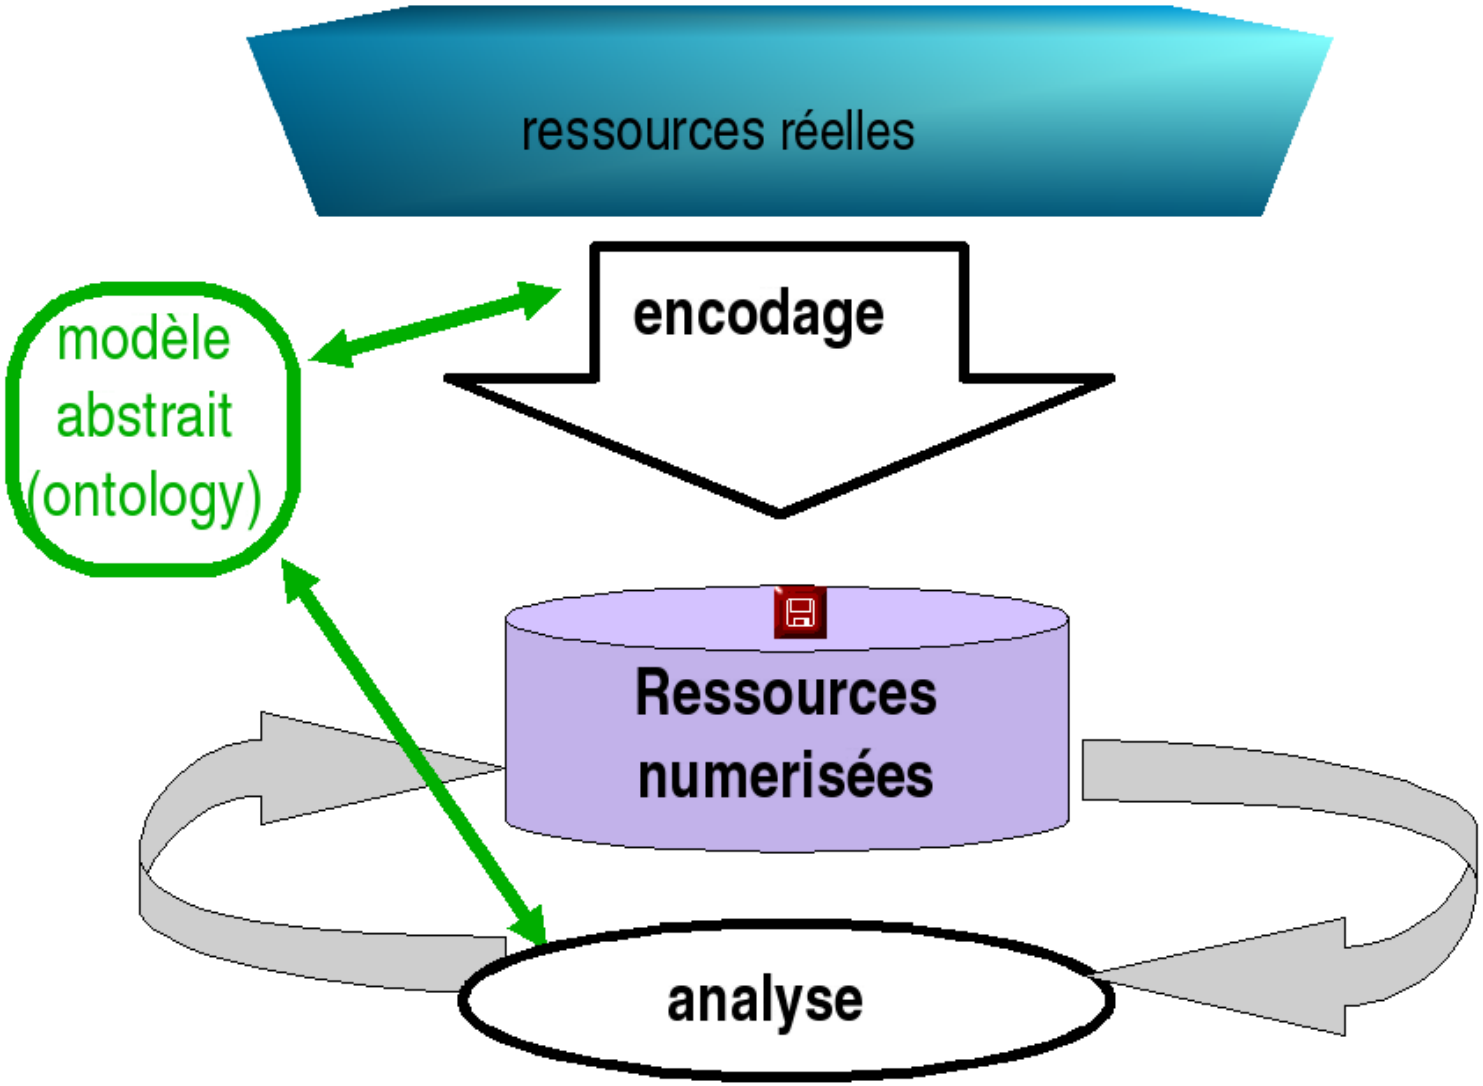

# La TEI pourrait nous aider...

Elle représente un modèle conceptuel de texte bien établi qui facilite :

- la conversion des données existantes
- la création des données nouvelles
- l'intégration des données déjà existantes mais répandues dans plusieurs sources

Elle est basée sur des formats ouverts et des technologies ouvertes

Elle s'appuie sur une théorie explicite de l'ontologie textuelle

# Est-ce que ceci représente la même chose ?

A MONSEI-
GNEVR LE REVE-
rendiſſime Cardinal
du Bellay.
S.

EV le Perſonnaige, que tu ioues au Spectacle de toute l'Europe, uoyre de tout le Monde en ce grand Theatre Romain, ueu tant d'affaires, & telz, que ſeul quaſi tu ſoutiens: ô l'Hõneur du ſacré College! pecheroy'-ie pas (comme dit le Pindare Latin) contre le bien publicq', ſi par longues paroles i'empeſchoy' le tens, que tu donnes au ſeruice de ton Prince, au profit de la Patrie, & à l'accroiſſement de ton immortelle renommée? Epiant donques quelque heure de ce peu de relaiz, que tu prens pour reſpirer ſoubz le peſant faiz des affaires Francoyſes (charge urayement digne de ſi robuſtes epaules, non moins que le Ciel de celles du grand Hercule) ma Muſe a pris la hardieſſe d'ẽtrer au ſacré Cabinet de tes ſainctes, & ſtudieuſes occupations: & la entre tant

a ij de

A MONSEIGNEUR

*Le Reverendiſſime Cardinal du Bellay, S.*

Veu le personnaige que tu joues au spectacle de toute l'Europe, voyre de tout le monde, en ce grand theatre romain; veu tant d'affaires et telz, que seul quasi tu soutiens : ô l'honneur du sacré College! pecheroy'-je pas (comme dit le Pindare latin) contre le bien publicq', si par longues paroles j'empeschoy' le tens que tu donnes au service de ton Prince, au profit de la patrie, et à l'accroissement de ton immortelle renommée? Epiant donques quelque heure de ce peu de relaiz, que tu prens pour respirer soubz le pesant faiz des affaires francoyses (charge vrayement digne de si robustes epaules, non moins que le ciel de celle du grand Hercule), ma Muse a pris la hardiesse d'entrer au sacré cabinet de tes saintes et studieuses oc-

# Et ceci ?

A MONSEI-
GNEVR LE REVE-
rendiſſime Cardinal
du Bellay.
S.

VEV le Perſonnaige, que tu ioues au Spectacle de toute l'Europe, uoyre de tout le Monde en ce grand Theatre Romain, ueu tant d'affaires, & telz, que ſeul quaſi tu ſoutiens: ô l'Hõneur du ſacré College! pecheroy'-ie pas (comme dit le Pindare Latin) contre le bien publicq', ſi par longues paroles i'empeſchoy' le tens, que tu donnes au ſeruice de ton Prince, au profit de la Patrie, & à l'accroiſſement de ton immortelle renommée? Epiant donques quelque heure de ce peu de relaiz, que tu prens pour reſpirer ſoubz le peſant faiz des affaires Francoyſes (charge urayement digne de ſi robuſtes epaules, non moins que le Ciel de celles du grand Hercule) ma Muſe a pris la hardieſſe d'ẽtrer au ſacré Cabinet de tes ſainctes, & ſtudieuſes occupations: & la entre tant

a ij de

A MONSEIGNEUR

*Le Reverendiſſime Cardinal du Bellay, S.*

Veu le personnaige que tu joues au spectacle de toute l'Europe, voyre de tout le monde, en ce grand theatre romain: veu tant d'affaires et telz, que seul

**Joachim du Bellay**

**Défense et illustration de la langue françoyse (1549)**

La Deffence, et Illustration de la Langue Francoyse

**L'auteur prie les lecteurs différer leur jugement jusques à la fin du livre, et ne le condamner sans avoir premièrement bien vu, et examiné ses raisons.**

Épître à Monseigneur le révérendissime cardinal du Bellay S.

Vu le personnage que tu joues au spectacle de toute l'Europe, voire de tout le monde, en ce grand Théâtre Romain, vu tant d'affaires, et tels que seul quasi tu soutiens, ô l'honneur du sacré Collège, pécherai-je pas (comme dit le Pindare Latin) contre le bien public, si par longues paroles j'empêchais le temps que tu donnes au service de ton prince, au profit de la patrie et à l'accroissement de ton immortelle renommée ? Épiant donc quelques heures de ce peu de relais que tu prends pour respirer sous le pesant faix des affaires françaises (charge vraiment digne de si robustes épaules, non moins que le ciel de celles du grand Hercule), ma Muse a pris la hardiesse d'entrer au sacré cabinet de tes saintes et studieuses occupations : et là, entre tant de riches et excellents voeux de jour en jour dédiés à l'image de ta grandeur, pendre le sien humble et petit, mais toutefois bien heureux s'il rencontre quelque faveur devant les yeux de ta bonté, semblable à celle des Dieux immortels, qui n'ont moins agréables les pauvres présents d'un bien riche vouloir que les superbes et ambitieuses offrandes.

# Un texte n'est pas un document...

En quoi consiste l'essentiel d'un texte ?

- en l'apparence des lettres et leur mise-en-page ?
- en la version originelle (supposée) de cette copie ?
- en les interprétations/lectures apportées ou trouvées ?
- en les intentions (supposées) de son auteur ?

Un 'document' est une chose physique, que nous pouvons *numériser*.

Un 'texte' est une abstraction construite par, ou pour, une communauté de lecteurs, que nous pouvons *encoder*.

# Un texte n'est pas un document...

En quoi consiste l'essentiel d'un texte ?

- en l'apparence des lettres et leur mise-en-page ?
- en la version originelle (supposée) de cette copie ?
- en les interprétations/lectures apportées ou trouvées ?
- en les intentions (supposées) de son auteur ?

Un 'document' est une chose physique, que nous pouvons *numériser*.

Un 'texte' est une abstraction construite par, ou pour, une communauté de lecteurs, que nous pouvons *encoder*.

# Un texte n'est pas un document...

En quoi consiste l'essentiel d'un texte ?

- en l'apparence des lettres et leur mise-en-page ?
- en la version originelle (supposée) de cette copie ?
- en les interprétations/lectures apportées ou trouvées ?
- en les intentions (supposées) de son auteur ?

Un 'document' est une chose physique, que nous pouvons *numériser*.

Un 'texte' est une abstraction construite par, ou pour, une communauté de lecteurs, que nous pouvons *encoder*.

# Un texte n'est pas un document...

En quoi consiste l'essentiel d'un texte ?

- en l'apparence des lettres et leur mise-en-page ?
- en la version originelle (supposée) de cette copie ?
- en les interprétations/lectures apportées ou trouvées ?
- en les intentions (supposées) de son auteur ?

Un 'document' est une chose physique, que nous pouvons *numériser*.

Un 'texte' est une abstraction construite par, ou pour, une communauté de lecteurs, que nous pouvons *encoder*.

# Un texte n'est pas un document...

En quoi consiste l'essentiel d'un texte ?

- en l'apparence des lettres et leur mise-en-page ?
- en la version originelle (supposée) de cette copie ?
- en les interprétations/lectures apportées ou trouvées ?
- en les intentions (supposées) de son auteur ?

Un 'document' est une chose physique, que nous pouvons *numériser*.

Un 'texte' est une abstraction construite par, ou pour, une communauté de lecteurs, que nous pouvons *encoder*.

# L'encodage

- Un texte est plus qu'une séquence de caractères encodés !
- Un texte est plus qu'une séquence de formes lexicales !
  - Il a une structure et une signification
  - Un texte peut avoir plusieurs lectures variantes
  - La portée d'un texte peut être enrichie par des annotations
- L'encodage explicite les lectures
- Sans explicitation, on ne peut rien traiter

# L'effet Babel

Bien sûr il existe plusieurs lectures possibles pour la plupart des textes...

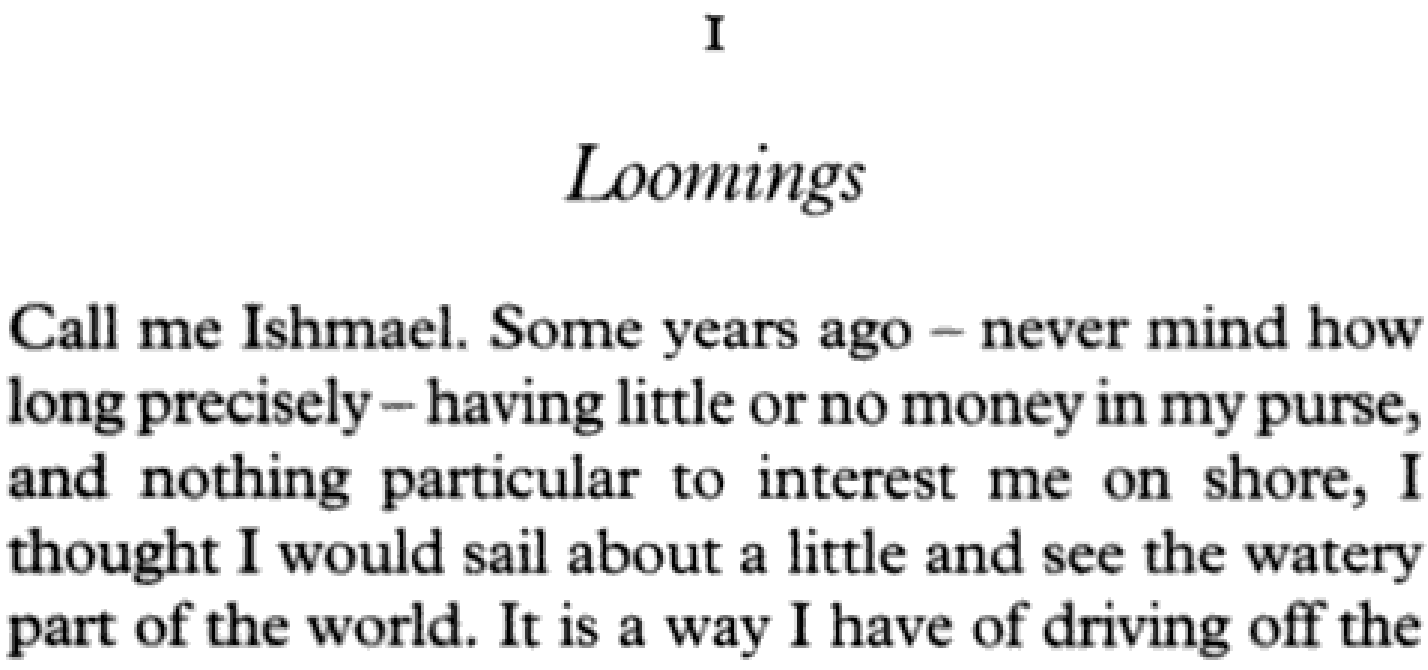

I

*Loomings*

Call me Ishmael. Some years ago – never mind how long precisely – having little or no money in my purse, and nothing particular to interest me on shore, I thought I would sail about a little and see the watery part of the world. It is a way I have of driving off the

... et (malheureusement) plusieurs manières d'expression pour ces lectures !

# Encodage ou Babel ?

```
|chap1
<C 1> Loomings
\chapter[1]{Loomings}
:h1.1.  Loomings
MOBY001001LOOMINGS
|C1
.chapter Loomings
.cp;.sp 6 a;.ce .bd 1. Loomings
<h1>Loomings</h1>
<p class="h1">Loomings
~x
```

- Bonne nouvelle : il existe des logiciels capables de traduire entre 500 formats divers
- Mauvaise nouvelle : on en a besoin !

# Encodage ou Babel ?

```
|chap1
<C 1> Loomings
\chapter[1]{Loomings}
:h1.1.  Loomings
MOBY001001LOOMINGS
|C1
.chapter Loomings
.cp;.sp 6 a;.ce .bd 1. Loomings
<h1>Loomings</h1>
<p class="h1">Loomings
~x
```

- Bonne nouvelle : il existe des logiciels capables de traduire entre 500 formats divers
- Mauvaise nouvelle : on en a besoin !

# Encodage ou Babel ?

```
|chap1
<C 1> Loomings
\chapter[1]{Loomings}
:h1.1.  Loomings
MOBY001001LOOMINGS
|C1
.chapter Loomings
.cp;.sp 6 a;.ce .bd 1. Loomings
<h1>Loomings</h1>
<p class="h1">Loomings
~x
```

- Bonne nouvelle : il existe des logiciels capables de traduire entre 500 formats divers
- Mauvaise nouvelle : on en a besoin !

# Échange d'informations (1)

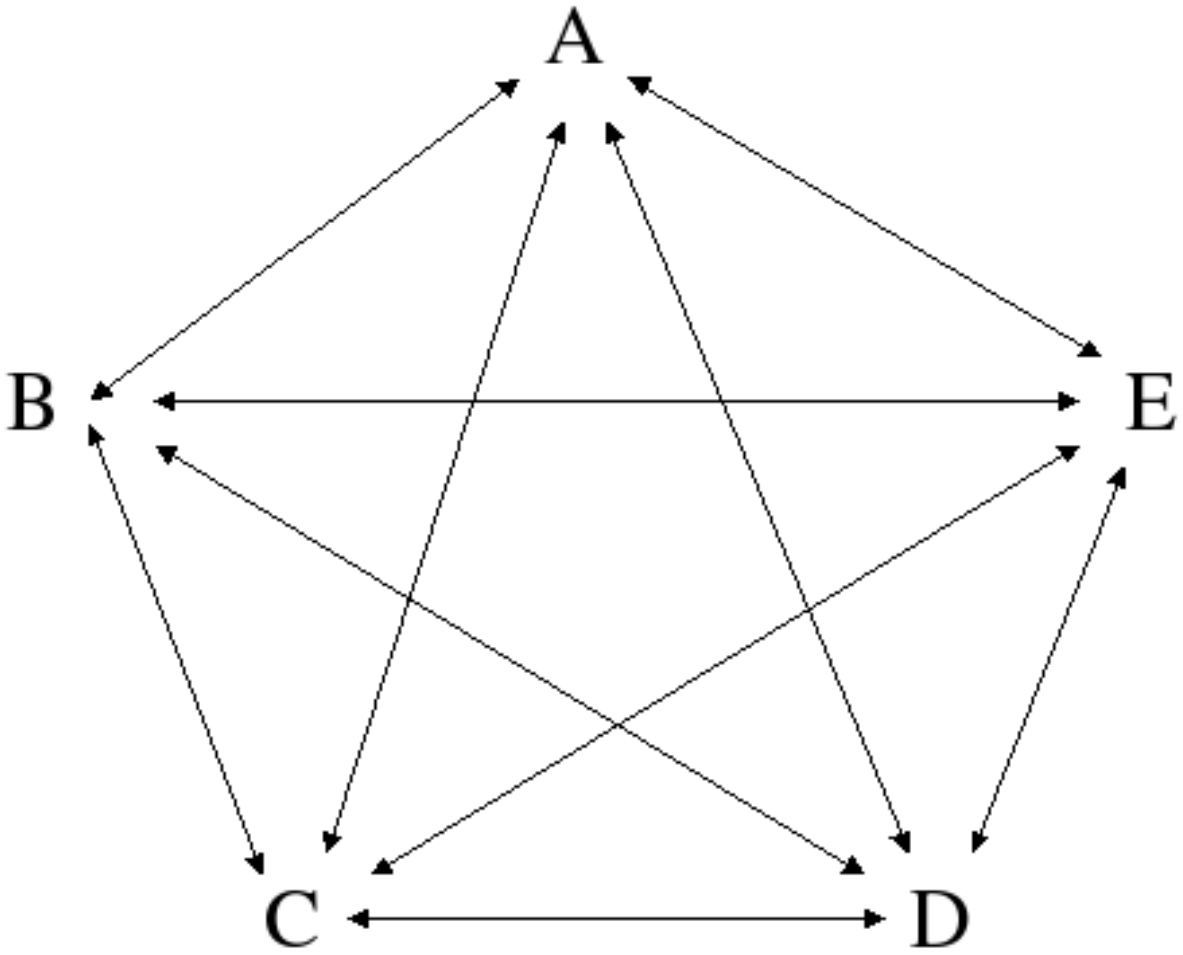


*sans format pivot: 20 passerelles requises (n*n-n)*

# Échange d'informations (2)

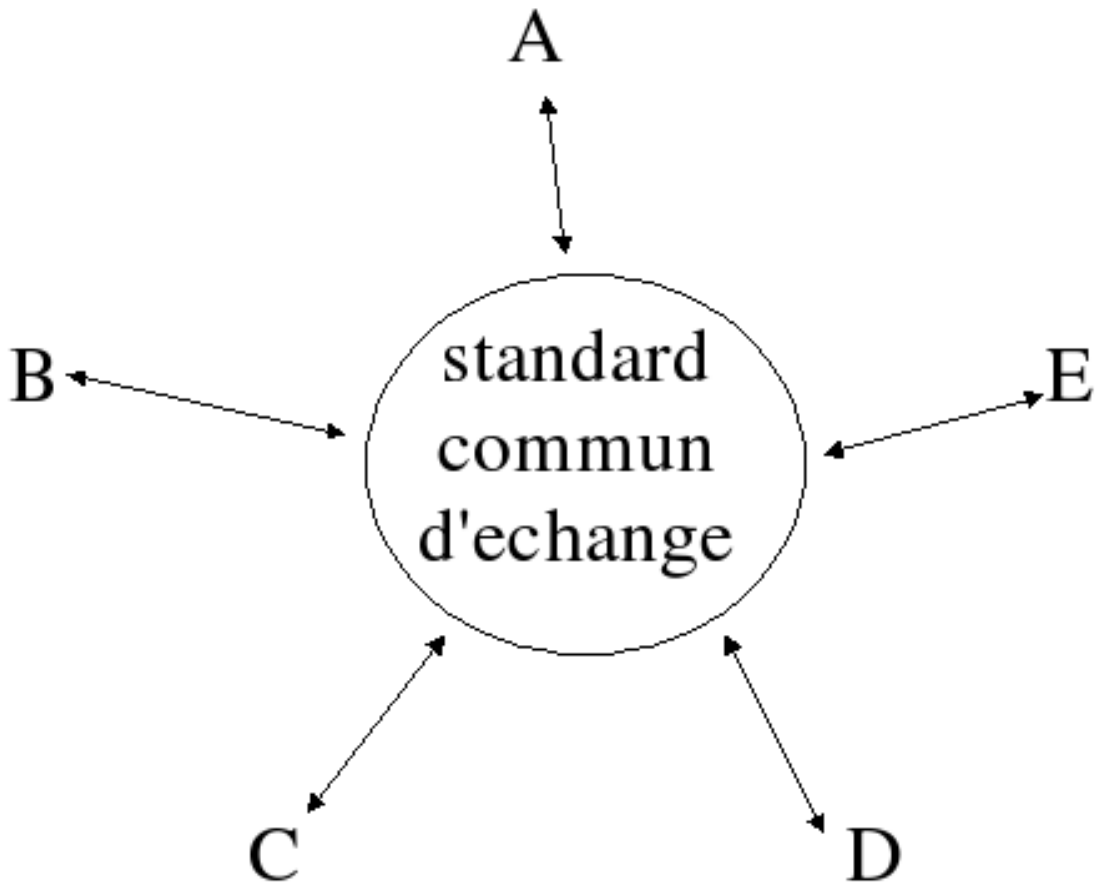


*avec format pivot: 10 passerelles requises (2n)*

# Définitions

- Un balisage explicite les distinctions qu'on désire faire en traitant une chaîne de caractères
- Le balisage est une manière de nommer et de caractériser les composants d'une structure textuelle, d'une manière quasiment formelle
- Quel genre de composants ? La réponse dépend des usages prévus...

# Séparation de forme et contenu

- Un balisage descriptif s'intéresse plus au contenu qu'à sa mise en forme
  - cette séparation facilite la réutilisation
  - et augmente la flexibilité
- Un balisage présentationnel, par contre, s'intéresse plus à l'affichage qu'à sa sémantique

# Séparation de forme et contenu

- Un balisage descriptif s'intéresse plus au contenu qu'à sa mise en forme
  - cette séparation facilite la réutilisation
  - et augmente la flexibilité
- Un balisage présentationnel, par contre, s'intéresse plus à l'affichage qu'à sa sémantique

# Séparation de forme et contenu

- Un balisage descriptif s'intéresse plus au contenu qu'à sa mise en forme
  - cette séparation facilite la réutilisation
  - et augmente la flexibilité
- Un balisage présentationnel, par contre, s'intéresse plus à l'affichage qu'à sa sémantique

# Séparation de forme et contenu

- Un balisage descriptif s'intéresse plus au contenu qu'à sa mise en forme
  - cette séparation facilite la réutilisation
  - et augmente la flexibilité
- Un balisage présentationnel, par contre, s'intéresse plus à l'affichage qu'à sa sémantique

# Séparation de forme et contenu

- Un balisage descriptif s'intéresse plus au contenu qu'à sa mise en forme
  - cette séparation facilite la réutilisation
  - et augmente la flexibilité
- Un balisage présentationnel, par contre, s'intéresse plus à l'affichage qu'à sa sémantique

# Qu'est ce qu'on balisera ?

Comparer :

```
<pb n="4"/>A MONSEI- <lb/>GNEUR LE REVE-
<lb/>rendissime Cardinal <lb/>du Bellay. <lb/>S
<lb/>
<c rend="lettrine">V</c>EU le
Personnaige, <lb/>que tu joues au Spec- <lb/>tacle de toute
l'Europe...
```

avec

```
<div type="dedicace">
 <head>A MONSEIGNEUR LE REVERENDISSIME CARDINAL DU
BELLAY</head>
 <salute>S<ex>alut</ex>
 </salute>
 <p>
  <c rend="lettrine">V</c>EU le Personnaige, que tu joues
au Spectacle de toute
   l'Europe... </p>...
</div>
```

# ... et avec

```
<pb n="4"/>
<s>
 <w pos="PPJ" lemma="voir">VEU</w>
 <w pos="ART" lemma="le">le</w>
 <w pos="SBC" lemma="personnage">Personnaige</w>
 <pc>,</pc>
 <w pos="COO" lemma="que">que</w> ...
</s>
```

ou bien

```
<s>
 <choice>
  <reg>Vu</reg>
  <orig>Veu</orig>
 </choice> le
<choice>
  <reg>Personnage</reg>
  <orig>Personnaige</orig>
 </choice>, que tu joues au
Spectacle...
</s>
```

# Notre système d'encodage devrait être capable de…

- spécifier les caractères d'un texte
- expliciter la/les structures aperçue/s dans un texte
- linéariser le texte
- spécifier les méta-informations, renseignements contextuels etc.
- prendre en compte la sémantique de la texte

Jusqu'à présent, XML semble une bonne solution...

# La bonne soupe d'acronymes

| | |
|---|---|
| SGML | Standard Generalized Markup Language |
| HTML | Hypertext Markup Language |
| W3C | World Wide Web Consortium |
| XML | eXtensible Markup Language |
| DTD | Document Type Definition (or Declaration) |
| CSS | Cascading Style Sheet |
| Xpath | XML Path Language |
| XSLT | eXtensible Stylesheet Language - Transformations |
| RelaxNG | Regular Expression Language for XML (New Generation) |

à ne pas oublier TEI, la *Text Encoding Initiative*

# XML: ce que c'est et pourquoi on devrait le connaître

- XML est une manière de représenter les données structurées sous forme de chaîne de caractères
- un document XML ressemble à un document HTML, sauf que :
  - XML est extensible
  - un document XML doit être *bien formé*
  - un document XML peut être *valide*
- XML est indépendant de l'application, de la plate-forme et du vendeur
- XML rend le pouvoir aux fournisseurs de données, et facilite l'intégration des ressources diverses et polyglottes

# XML en 4 points

1. XML ne sert pas à afficher les données mais à les décrire
2. Le nom des balises n'est pas prédéfini
3. On peut utiliser une "grammaire" de balises
4. XML est auto-descriptif et lisible par l'homme

# Exemple d'un document XML complet

```
 <?xml version="1.0"?>
<doc xmlns="http://example.org/namespace">
 <p n="1">This is a paragraph.</p>
 <p n="2">This paragraph mentions
<placeName>Bristol</placeName>.</p></doc>
```

# (Presque) tout ce qu'il faut savoir au sujet de XML, sur un seul transparent

- Un document XML contient au moins un *élément*
- Un élément possède une *balise d'ouverture*, facultativement de *contenu* et une *balise de fermeture*
- Un élément peut d'ailleurs porter des *attributs*, chacun portant un *nom* et une *valeur*
- Un document XML est *obligatoirement* 'well formed' (bien-formé) i.e. il doit suivre la syntaxe XML
- Un document bien-formé peut *facultativement* être *valide* i.e. il est conforme aux règles d'un *schéma* quelconque

```
<?xml version="1.0" ?>
  <root>
    <element attribute="value"> content </element>
    <!-- comment -->
  </root>
```

# Encore un petit document XML

```xml
<?xml version="1.0" encoding="UTF-8"?>
<cookBook>
    <recipe n="1">
        <head>Soupe de pierre</head>
        <ingredientList>
            <ingredient>un oignon</ingredient>
            <ingredient>deux carottes</ingredient>
            <ingredient>de l'eau</ingredient>
               <!-- d'autres ingrédients -->
            <ingredient>une pierre</ingredient>
            <ingredient>des paysans naïfs</ingredient>
        </ingredientList>
        <procedure>
            <step>mettre l'eau à bouillir dans un grand chaudron</step>
           <!-- d'autres étapes -->
            <step>enlever la pierre et servir</step>
        </procedure>
    </recipe>
    <recipe n="2">
        <!-- deuxieme recette ici -->
    </recipe>
    <!-- hic desunt multa -->
</cookBook>
```

# Syntaxe XML

Un document XML contient :

- des *éléments*, qui portent (facultativement) des *attributs*, marqués par des *balises*
- des *commentaires*
- des *instructions de traitement*
- des *références à entité* (interne ou externe)
- des *sections CDATA*
- ... et des caractères Unicode

C'est tout !

# XML: règles du jeu

- Un document XML représente une arborescence composée de *nœuds*
- il y a un seul nœud racine qui contient tous les autres
- chaque nœud peut être
  - une arborescence
  - un *élément* (qui porte facultativement des *attributs*)
  - une chaîne de caractères
- Chaque élément porte un nom ou *identification générique* (gi)
- Chaque attribut porte un nom et une valeur
- les noms sont liés avec un *namespace* (espace de noms)

# Représentation d'une arborescence XML

- Un document XML linéarisé commence par une instruction de traitement spécial
- Les occurrences d'élément sont marquées entre *balises ouvrantes* et *balises fermantes*
- Les paires nom/valeurs qui constituent les attributs d'un élément peuvent apparaître sans ordre à l'intérieur d'une balise ouvrante
- Les caractères < et & sont Magiques et doivent être cachés au moyen de références entité (< et & respectivement)
- L'espace de noms auquel appartient un élément peut être signalé par un *namespace-prefix* (p.e. xml:) prédéfini
- Les *commentaires* sont délimités par <!-- et -->
- Les *références entité* sont délimités par & et ;
- Les *sections CDATA* sont délimités par <![CDATA[ et ]]>

# Syntaxe XML : le "fine print"

Pour qu'un document soit *bien formé*, il faut que :

1. une seul racine contienne le document entier
2. chaque arborescence soit proprement imbriquée
3. tous les noms soient sensibles à la casse
4. chaque balise ouvrante ait sa balise fermante (sauf qu'on peut combiner les deux, le nœud étant vide)
5. les valeurs d'attribut soient présentées correctement entre guillemets

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# Bien formé ? oui ou non ?

- `<seg>some text</seg>`
- `<seg><foo>some</foo> <bar>text</bar></seg>`
- `<seg><foo>some <bar></foo> text</bar></seg>`
- `<seg type="text">some text</seg>`
- `<seg type='text'>some text</seg>`
- `<seg type=text>some text</seg>`
- `<seg type = "text">some text</seg>`
- `<seg type="text">some text<seg/>`
- `<seg type="text">some text<gap/></seg>`
- `<seg type="text">some text< /seg>`
- `<seg type="text">some text</Seg>`

# XML est un standard international

- Un document XML doit respecter le standard ISO 10646 (aka Unicode)
  - un répertoire de caractères 31-bit adéquate à la plupart des systèmes d'écriture humaine
  - encodé en deux formats UTF8 ou UTF16
- un document peut spécifier qu'il contient les mêmes caractères encodés d'une autre manière (notamment ISO 8859)
- un élément peut spécifier le langage de son contenu avec l'attribut prédéfini *@xml:lang*

Un attribut *@xml:id* est également prédéfini par le W3C.

# Validation XML

Un document XML *valide* est (bien sûr) bien formé, et en plus conforme à des règles supplémentaires, qui constituent un *schéma*

Avec un schéma, on peut spécifier :

- les nom des éléments qui constituer la racine d'un document
- les noms de tous les éléments légaux
- les noms, les types, et les valeurs par défaut de tous les attributs
- des règles concernant l'imbrication et le contenu des éléments
- et quelques autres menus propos...

Un schéma donc vous permet de contrôler par exemple que 'tout chapitre ait son titre', que 'toute recette comporte une liste d'ingrédients', que 'le valeur de tout attribut *@when* soit conforme au standard ISO' ... etc.

Un espace de noms, par contraste, ne vous permet que de labelliser : vocabulaire d'où est dérivé un ensemble d'éléments.

# Langues de schéma

Un schéma est exprimé dans une langue formelle. Actuellement, on peut choisir entre :

- WSD : langage schéma du W3C
- RNG : norme ISO Relax NG
- DTD : norme ISO

La TEI se sert de Relax NG

# Exercice 1

D’abord, nous allons expérimenter un logiciel spécialisé pour créer et modifier des fichiers XML...